

DGX GB10 Console

DGX Spark 集群 即時狀態 × 效能 × 健康監控平台

一部 HTTP API，實時睇晒你部 DGX 做緊咩 — 硬體、軟體、vLLM 推理效能、成本、告警

適用於 2 至 N 部 DGX Spark （GB10 Grace Blackwell）

客戶痛點：你很哩緊部 DGX，但「佢喺度做緊乜？」

無可視化 → 過熱降頻、OOM、排隊爆煲、磁碟滿、成本失控，全部唔知

- 只知道部機「著咗」，但唔知 GPU 係咪過熱緊→降頻，效能偷偷流失
- vLLM 排緊幾多 request？TTFT 有冇爆炸？邊個 model 最夾樽頸？
- 磁碟幾時滿？NVMe 幾時壞？能耗同 Token 成本每月幾多？
- 要逐部機 SSH 去睇 nvidia-smi，N 部機睇到頭都大
- 出事先發現，SLA / 收入無形損失

產品：一部 HTTP API 睇晒成個集群

N 節點星型架構 · 每部 DGX 一個 exporter · 一部 aggregator 合併

硬體健康

GPU / CPU / 記憶體 (UMA)
/ 溫度 / 功率
過熱降頻矩陣 · 節流偵測 ·
NVMe 壽命

vLLM 效能

tok/s · TTFT / ITL / e2e ·
queue
KV cache · per-model ·
SLO

成本 / 容量

能耗與電費 · Token 會計
磁碟 TTF · KV / 記憶體
headroom

可靠 / 安全

container OOM · kernel
log
security audit · RDMA 擁
塞

由 2 部到 N 部，輕鬆擴展

星型架構 · 每部節點都係一等公民 · 加機只需 3 步



add 一部：改 config 加一行 nodes[] + 喺新機跑 `install.sh --node-id=<id>` —— 自動出現嘅 snapshot

硬體健康 · 過熱降頻一眼睇到

GB10 統一記憶體 (UMA) 專屬做法 — 唔靠報 N/A 嘅 nvidia-smi VRAM

- GPU：util / 溫度 / 功率 / 時脈 / throttle reason（熱 vs 功率 vs 卡死）
- 熱降頻觀測矩陣：溫度 + SM 頻率比率 + throttle bit + 負載 夾埋判
- CPU / 記憶體 (UMA) / 磁碟 (NVMe SMART 壽命) / 網絡 (Fabric RDMA)
- 節流史 timeline：幾時降頻、持續幾耐 — 自動計入告警
- GB10 特有「卡死低時脈」bug 偵測（USB-C PD 供電）

vLLM 推理效能 — 一個 API 真正主角

喺 Docker 入面跑嘅 vLLM，直接撈 `/metrics · /health · /v1/models · /is_sleeping`

- 吞吐：decode / prefill tok/s，RPS（完成 request 率）
- 延遲：TTFT、ITL/TPOT、e2e — avg + P95（窗口度率，唔抄即時數）
- 積壓：running / waiting 隊列，per-model backlog，queue time
- KV-cache 用率、prefix-cache hit rate、preemption
- per-model SLO goodput；engine sleep / idle / dead 狀態

想知佢有冇排隊？

num_requests_waiting ↑ + queue_time
↑ = 積壓緊、處理緊

唔係掛咗 — 係 vLLM 自己排隊消化緊

成本透明 · 容量先知

唔使估 — 幾多電、幾多 Token、幾時滿，全部數字化

- 能耗：整機 wall power (spbm)，kWh/日，電費 (\$/kWh)
- idle vs active 成本分帳：幾多電係白拎
- Token 會計：per-model 每日 tokens、\$/1M tokens、cache 慳幾多
- 預算告警：\$ 突破 80% / 100% 即知

容量預測

- disk TTF：幾時 full (4h / 6h 預警)
- KV / 記憶體 headroom 趨勢 (UMA)
- 「要唔要加 node」呢啲問題有數據答

可靠監察 · 安全守門

- NVMe 壽命預測 + critical warning （呢個平台有已知 No-NVMe 故障）
- container OOM / restart loop → 即時警報
- kernel / OOM / NVRM 日誌 markers （24h 有事冇事一目了然）
- 睇 log：`/logs` 攞 vLLM / kernel / 服務 / container 日誌（限行數 + auth）
- security audit：open ports、failed SSH、異常 process/container

安全

- API read-only 預設 + Token / API-Key
- 站與站用 mTLS 或 WireGuard 加密
- vLLM 控制（可選）受控 + 唔 auto-wake

即時告警 — 未出事已經話你知

成個集群一套 alert 規則， Predomtheus / Grafana 或內建 /metrics

NVMe wear / critical warning	將壞碟，先換先安	CRIT
GPU > 96°C / SM clock 崩	過熱降頻 / USB-C PD 卡死	CRIT
Disk TTF < 6h	磁碟就快快滿	
KV cache 飽和 + 排隊 + preempt	模型唔夠位，要加 node	
RDMA link down / 擁塞升	fabric 出問題	CRIT
vLLM engine dead (health≠200)	推理死機，即刻喊	CRIT

架構 — 分層清晰，通訊安全

- L4 Consumer：你部機 / Prometheus / Grafana
- L3 API：aggregator (/health · /cluster.json · /metrics · /logs · /control
- L2 Exporter：每部 DGX 一個 :9101 (一等公民)
- L1 Collectors：hardware · system · network · services · vllm (並行)
- L0 數據源：nvidia-smi / proc / sys / docker / vLLM / RDMA

通訊安全

- 出外：token + read-only + TLS
- 站與站：mTLS / WireGuard 加密
- /logs 敏感 → auth；/control 受控

部署 — 幾分鐘上線、遷移就把炮

- 每節點 venv + systemd (原裝 DGX OS , ARM64 wheels 齊)
- 冪等 install.sh : `--role --node-id --mgmt-ip` , 加機 3 步
- hardened systemd unit (NoNewPrivileges / ProtectSystem ...)
- 可選 Docker 路徑
- 換機／升級: `install.sh --update` / `--uninstall` 回滾

部署三句

- ① clone + install.sh
- ② 定 token / 角色
- ③ 起 service — 完成

整合 — 唔係孤島

- Prometheus / Grafana：內建 /metrics 直接被撈 → dashboard + alert
- Webhook / Telegram（可選）：出事即 push
- SQLite 歷史 / ring buffer：即時 + 回溯（可配 Prometheus TSDB 長史）
- vLLM 控制（可選）：abort-by-id、pause/resume — 受控 + 唔干預

想擴到大型集群？

N 前預設單 aggregator；N 大到可 federation / 多級

客戶價值

- ✓ 唔使估 — 成個集群即時狀態、效能、成本一目了然
- ✓ 過熱降頻 / OOM / 排隊 / 磁碟滿 / 將壞碟 — 未出事已經話你知
- ✓ 效能 SLA 有得查：TTFT / P95 / per-model — 唔使靠估
- ✓ 成本透明：電費、Token、容量預測 — 慳錢決定有數據
- ✓ 安全守門：read-only + mTLS + 受控操作

由「唔知」到「一個 API 就知」 — DGX GB10 Console

下一步

落地試行：喺你嘅 DGX Spark 上部署概念驗證
接入你嘅 vLLM / 監控棧，睇住真實數據
按你需要收窄或擴展收嘅指標

DGX GB10 Console — 謝謝